

Коммерческое предложение

DataEyes — единый доступ к frontier-моделям + независимый бенчмарк качества

Для: партнёров и интеграторов **Дата:** 14 июня 2026 **Подготовил:** Данил Силантьев, представитель
Статус: конфиденциально, для обсуждения

Каталог моделей, точки входа и диапазоны скидок в этом документе сверены с актуальной витриной и документацией **dataeyes.ai** (Model Hub / pricing). Бенчмарк-цифры в разделе 6 — иллюстративный прогон по реальному каталогу, воспроизводимый на вашем ключе. Методология цен и оговорки — в разделе 12.

1. Резюме

DataEyes — это единый OpenAI-совместимый API-шлюз к десяткам frontier-моделей ведущих вендоров (OpenAI, Google, Anthropic, DeepSeek, Alibaba, Moonshot, ByteDance, MiniMax, Z.AI, Xiaomi) через **один ключ и один интерфейс**, с мульти-региональными точками входа (Global / International / Китай).

Главное коммерческое преимущество — **цена ниже прямого доступа к вендору на все модели**: DataEyes отдаёт каждую модель со скидкой к официальному vendor-прайсу (публично — **от 10% до 90%** в зависимости от модели и тарифа ресурса), плюс действуют **volume-скидки**. Поверх доступа мы даём **объективную систему выбора модели**: открытый бенчмарк-сервис, который измеряет качество, скорость, стоимость и надёжность каждой модели на воспроизводимых задачах и трассирует всё в Langfuse. Это снимает главный риск интеграции LLM — «какую модель брать под задачу и бюджет» — превращая его из догадок в измеримое решение.

Что получает партнёр: - скидка на все модели к vendor-прайсу (10–90%) + volume-скидки — прямая экономия бюджета; - один контракт и один API вместо десятка интеграций с разными вендорами; - независимые, воспроизводимые данные о качестве/латентности/стоимости моделей; - готовый слой наблюдаемости и контроля затрат; - быстрый онбординг (drop-in замена OpenAI-клиента).

2. О платформе DataEyes

DataEyes (бренд 数眼 / **DataEyes**) — унифицированный интерфейс к множеству LLM. Ключевые свойства (подтверждены технической интеграцией):

- **Единый OpenAI-совместимый API** — `chat/completions`, Responses API, streaming, function calling. Дополнительно поддерживаются **Anthropic-совместимый** и **Gemini-совместимый** форматы — миграция с существующего стека минимальна.
- **Динамический каталог моделей** — `GET /v1/models`: список доступных моделей определяется вашим ключом, без хардкода. Каталог покрывает текст/LLM, мультимодальные, image и video-модели.

- **Web Search / Reader API** — отдельные собственные сервисы живого веб-поиска и парсинга страниц (`api.dataeyes.ai`) для агентных сценариев.
- **Политика приватности** — промпты не логируются и не используются для обучения («your prompts never logged or trained»).
- **Мульти-регион** — несколько точек входа для отказоустойчивости и близости к рынку:

Регион / назначение	Точка входа
Global (Кремниевая долина, прямое подключение)	<code>https://cloud.dataeyes.ai/v1</code>
International (high-defense, CF-кластер)	<code>https://platform.dataeyes.ai/v1</code>
Китай (КНР, выделенный CDN)	<code>https://cloud-cn.shuyanai.com/v1</code>
Web Search / Reader API	<code>https://api.dataeyes.ai</code>

- **Аутентификация** — `Authorization: Bearer <key>` (ключ выдаётся в консоли после регистрации).
- **Документация** — `dataeyes.ai` , `doc.dataeyes.ai` .

Юридические реквизиты вендора, официальные SLA и сертификации (data residency, ISO/SOC2 и т.п.) уточняются у DataEyes — см. раздел 12.

3. Проблема, которую мы закрываем

«Много моделей через один ключ» — это удобство, но в продакшене партнёр сталкивается с типовыми проблемами интеграции. Ниже — реальные классы инцидентов, которые наш бенчмарк выявляет **до** вывода в прод:

#	Проблема интеграции	Последствие	Как закрываем
1	Несовместимость endpoint (например, отсутствие <code>/v1</code> в base URL)	Клиент падает на старте	Валидация конфигурации, корректные дефолты
2	Часть «рекламируемых» моделей недоступна конкретному ключу	Сюрприз в проде	Динамический discovery <code>/v1/models</code>
3	Разное качество tool-calling / function calling между моделями	Невалидные аргументы инструментов	Скоринг tool-accuracy + JSON-fallback
4	Большой разброс latency (особенно first-token) между моделями	Непредсказуемый UX	Замер p50/p95 латентности
5	Поле стоимости отсутствует в ответе API	Невозможно атрибутировать затраты	Локальный расчёт по референс-ценам, <code>cost_status</code> без фабрикаци
6	Трассировка теряется, если запрос обошёл шлюз	Нет наблюдаемости	Принудительная маршрутизация + Langfuse
7	Rate-limit (429) при конкурентных вызовах	Сбои нагрузки	Контролируемый параллелизм, лимиты на прогон
8	«Грязный» JSON (markdown-обёртки, <code><think></code> -блоки)	Срыв strict-схем	Санитайзинг и извлечение JSON

Вывод: ценность не только в широте каталога, но и в **объективной приёмке моделей** перед интеграцией.

4. Что мы предлагаем

- 1. **Доступ к платформе DataEyes** — единый API к каталогу frontier-моделей (раздел 5), мульти-регион, drop-in совместимость.
- 2. **Независимый бенчмарк-сервис** (`model-bench`, открытый код) — воспроизводимая оценка моделей по 10 наборам тестов (suites): от smoke-проверок и строгих JSON-схем до многошаговых reasoning-, code- и system-design-задач и 5–10-шагового агентного сценария.
- 3. **Слой наблюдаемости и экономики** — трассировка каждого вызова в Langfuse (латентность, токены, токены/сек, оценочная стоимость, оценки качества), хранение артефактов и сводных отчётов.
- 4. **Отчётность под партнёра** — выгрузка результатов прогонов в человекочитаемые отчёты (Markdown/PDF) для принятия решений и презентаций конечным клиентам.

5. Каталог моделей и партнёрская экономика

Доступ — к десяткам моделей ~10 вендоров через один API. Ключевые текст/LLM-модели актуального каталога DataEyes (Model Hub) и их **партнёрская цена**: ниже официального vendor-прайса за счёт скидки DataEyes к каждому ресурсу. «Vendor-прайс» — публичная ориентировочная цена вендора (USD за 1 млн токенов, вход/выход, июнь 2026), которую наш бенчмарк использует

как референс расчёта стоимости. «Ваша цена» — стабильный production-тариф через нас; на special/self-deployed и volume-тарифах скидка глубже (колонка «до -X%»). Методология — в разделе 12.

Модель	Вендор	Класс	Vendor-прайс вход/выход \$/1M	Ваша цена вход/выход \$/1M	Экономия vs vendor	Скидка DataEyes
claude-opus-4-6	Anthropic	Премиум	5 / 25	4.13 / 20.63	-17%	до -70%
gpt-5.4	OpenAI	Премиум	5 / 30	3.85 / 23.10	-23%	до -90%
gemini-3.1-pro-preview	Google	Премиум	2 / 12	1.65 / 9.90	-17%	до -70%
qwen3.6-plus	Alibaba	Премиум	2.50 / 7.50	1.93 / 5.78	-23%	до -55%
glm-5	Z.AI	Средний	1.20 / 4	0.92 / 3.08	-23%	до -55%
kimi-k2.5	Moonshot	Средний	0.60 / 2.50	0.46 / 1.93	-23%	до -55%
doubao-seed-2-0-pro	ByteDance	Средний	0.44 / 2.20	0.36 / 1.82	-17%	до -45%
deepseek-v3.2	DeepSeek	Эконом	0.435 / 0.87	0.29 / 0.57	-34%	до -90%
minimax-m2.5	MiniMax	Эконом	0.20 / 1	0.15 / 0.77	-23%	до -65%

Дополнительно в каталоге — мультимодальные, image и video-модели (например Nano Banana Pro / Gemini 3 Pro Image, Seedance 2.0, Grok Imagine) и собственные **Web Search / Reader API**. Полный список определяется динамически вашим ключом через `/v1/models`. Разброс цен между топовой и экономичной моделью — **до ~50x по выходным токенам**, поэтому правильный выбор модели под задачу даёт основную экономию **поверх** скидки на каждую модель.

6. Доказательство: результаты независимого бенчмарка

Ниже — **иллюстративный прогон** нашего инструмента по реальному каталогу DataEyes: набор `deep_eval` (4 задачи × 100 баллов = 400), по одной флагманской модели на вендора, 9 моделей. Задачи: многошаговый reasoning, генерация кода, строгое следование инструкции, QA по длинному контексту. Структура прогона воспроизводима на вашем ключе — вы получите сопоставимые артефакты по своим моделям и задачам.

#	Модель	Вендор	Балл / 400	Ср. латентность/задача
1	gpt-5.4	OpenAI	400	~9.2 с
1	gemini-3.1-pro-preview	Google	400	~9.5 с
1	minimax-m2.5	MiniMax	400	~5.7 с (самый быстрый)
1	glm-5	Z.AI	400	~23.6 с
1	doubao-seed-2-0-pro	ByteDance	400	~48.4 с
1	qwen3.6-plus	Alibaba	400	~56.9 с
7	claude-opus-4-6	Anthropic	390	~11.3 с
7	kimi-k2.5	Moonshot	390	~58.0 с
9	deepseek-v3.2	DeepSeek	340	~22.7 с

Ключевые выводы (воспроизводимы): - **Качество подтянулось у всех топ-вендоров:** 6 из 9 моделей — идеальные 400/400 на этом наборе. - **Лучший баланс «скорость x качество»:** `gpt-5.4`, `gemini-3.1-pro-preview`, `minimax-m2.5` — высший балл при низкой латентности (квадрант «быстро и точно»). `gemini-3.1-pro-preview` — лидер по пропускной способности (~200+ выходных токенов/сек). - **Скрытые риски latency:** `kimi-k2.5` и `qwen3.6-plus` дают высокий балл, но на задаче генерации кода доходят до **1.5–2.5 минут** на ответ — непригодны для интерактивных сценариев без оговорок. - **Самая сложная задача — QA по длинному контексту:** именно на ней «проседают» более слабые на этом наборе модели (`deepseek-v3.2`).

Это точечный замер на фиксированном наборе задач, а не непрерывный SLA-мониторинг. Бенчмарк воспроизводим: любой партнёр может перепрогнать его на своём ключе и своих задачах и получить сопоставимые артефакты.

7. Технологические преимущества

- **Цена ниже вендора на все модели.** Скидка к официальному vendor-прайсу на каждую модель (10–90% по каталогу) + volume-скидки — прямая экономия без потери качества.
- **Drop-in совместимость.** OpenAI / Anthropic / Gemini-форматы + Responses API + streaming + function calling — миграция существующего кода минимальна.
- **Приватность данных.** Промпты не логируются и не используются для обучения.
- **Мульти-регион и отказоустойчивость.** Global (Кремниевая долина) / International (CF high-defense) / CN точки входа; прямой fallback на DataEyes при недоступности шлюза.
- **Надёжность прогона.** Изоляция ошибок по моделям (падение одной модели не валит весь прогон — статус `partial`), жёсткий wall-clock timeout на вызов, санитайзинг «грязного» JSON, поддержка thinking-моделей (извлечение reasoning-контента).
- **Наблюдаемость.** Двухуровневая трассировка в Langfuse: токен-уровень (через шлюз LiteLLM) + прикладной уровень (run/case-спаны и оценки). Метаданные: run_id, suite, case_id, модель, вендор.

- **Экономика без фабрикаций.** Стоимость считается по прозрачной референс-таблице; если данных нет — честный статус `unknown`, а не выдуманное число.
- **Хранилище и экспорт.** PostgreSQL (прогоны, результаты, события, артефакты) + S3-совместимое хранилище (сырые ответы, отчёты, выгрузки) с локальным fallback.
- **Инженерная зрелость.** Открытый код, тесты (32 проходят), линт (ruff), CI/CD (тесты на Python 3.11/3.12, CodeQL, gitleaks, Dependabot) — прозрачно и проверяемо.

8. Модели сотрудничества для партнёров

Варианты (обсуждаемы и комбинируемы):

1. **Реселл / посредничество доступа** к DataEyes под ключ партнёра.
2. **Интеграция «под ключ»** — внедрение единого API + слоя наблюдаемости/экономики в продукт партнёра.
3. **Benchmark-as-a-service** — регулярные независимые прогоны под задачи партнёра с отчётами под его бренд (white-label).
4. **Совместный go-to-market** — пакетирование «доступ к моделям + объективный выбор модели» для конечных клиентов партнёра.

Конкретная модель, разделение зон ответственности и условия — предмет переговоров (раздел 10).

9. Как начать (внедрение)

1. **Доступ.** Партнёр получает ключ DataEyes; проверяем доступный каталог через `/v1/models`.
2. **Smoke-проверка.** Запускаем `smoke`-набор — подтверждаем связность, JSON-валидность, базовую латентность.
3. **Профильные наборы.** Подбираем suites под задачи партнёра (`json_schema`, `agent_mini`, `deep_eval`, `fast` и т.д.).
4. **Наблюдаемость.** Подключаем Langfuse — все вызовы, метрики и оценки видны в реальном времени.
5. **Решение.** По сводному отчёту (качество × латентность × стоимость) фиксируем модели под каждый сценарий.

Технически сервис поднимается за день: `make up && make migrate && make dev` (PostgreSQL + хранилище + шлюз), затем `curl /benchmarks/run`. Ориентировочный срок пилота — **[1–2 недели – согласовать]**.

10. Коммерческие условия

Параметр	Значение
Модель оплаты доступа к моделям	По факту потребления токенов по партнёрскому тарифу (раздел 5), ниже vendor-прайса
Скидка на модели	10–90% к официальному vendor-прайсу в зависимости от модели и тарифа ресурса; volume-скидки — по объёму
Стоимость внедрения / интеграции	Рассчитывается под объём работ, обсуждается индивидуально
Benchmark-as-a-service	По запросу: разовый прогон или регулярный мониторинг
Партнёрское вознаграждение / реселл	Обсуждается индивидуально
SLA, лимиты (RPM/TPM), поддержка	По договорённости (официальные SLA DataEyes уточняются у вендора)
Срок действия предложения	30 дней с даты подготовки (до 14 июля 2026)

Точные цифры формируются под профиль и объём партнёра — готов рассчитать после короткого созвона.

11. Контакты

- **Представитель:** Данил Силантьев
- **Email:** danilsilantyevwork@gmail.com
- **Проект / демо** (открытый бенчмарк): github.com/rldyourmnd/dataeyes
- **Telegram / телефон:** по запросу

12. Приложения и оговорки

- **Методология цен (раздел 5).** «Vendor-прайс» — публичная ориентировочная цена вендора (USD/1M токенов, июнь 2026), заложенная в бенчмарк как референс расчёта стоимости (DataEyes в ответах API стоимость не передаёт — она оценивается локально или помечается как недоступная). «Ваша цена» = vendor-прайс × коэффициент ресурса DataEyes (стабильный official-tier) × партнёрское представительство; цифры в разделе 5 рассчитываются из единого источника в коде (`benchsvc.scoring` , скрипт `scripts/compute_partner_pricing.py`), поэтому КП и инструмент согласованы. Диапазоны «до –X%» отражают публичные бейджи скидок dataeyes.ai (например DeepSeek 40–90%, Claude/Gemini 20–70%) и более глубокие special/self-deployed/volume-тарифы. **Точный per-token прайс по вашему ключу и объёму подтверждается в консоли DataEyes / по запросу.**
- **Источник результатов бенчмарка.** Раздел 6 — иллюстративный прогон `deep_eval` по реальному каталогу DataEyes (9 моделей, по одной на вендора). Это точечный замер на

фиксированном наборе задач, воспроизводимый на стороне партнёра; он не является непрерывным мониторингом или гарантией SLA.

- **Не подтверждены в материалах и требуют уточнения у DataEyes:** юридические реквизиты вендора, официальные SLA/uptime, сертификации и data residency (GDPR/SOC2/ISO 27001), точные лимиты тарифов, размеры контекстных окон.
- **Инструмент.** Бенчмарк-сервис (`model-bench`) — открытый код в монорепо `dataeyes` ; методология, наборы тестов, скоринг и расчёт цен прозрачны и проверяемы.

Документ подготовил Данил Силантьев на основе верифицируемых данных репозитория `dataeyes` и актуальной витрины `dataeyes.ai`. Точные тарифы по ключу/объёму, официальные SLA и сертификации подтверждаются у DataEyes; коммерческие детали — индивидуально по запросу.