

Коммерческое предложение

DataEyes — единый доступ к frontier-моделям + независимый бенчмарк качества

Для: партнёров и интеграторов **Дата:** 13 июня 2026 **Подготовил:** Данил Силантьев, представитель
Статус: конфиденциально, для обсуждения

Цифры бенчмарка в этом документе — результаты реальных прогонов нашего открытого инструмента (`model-bench`), верифицируемые по исходному коду репозитория. Источники цен и оговорки — в разделе 12.

1. Резюме

DataEyes — это единый OpenAI-совместимый API-шлюз к десяткам frontier-моделей ведущих вендоров (OpenAI, Google, Anthropic, DeepSeek, Alibaba, Moonshot, ByteDance, MiniMax, Zhipu AI, Xiaomi) через **один ключ и один интерфейс**, с мульти-региональными точками входа (Global / Китай / Гонконг).

Мы предлагаем партнёрам не просто доступ к моделям, а **доступ + объективную систему выбора модели**: открытый бенчмарк-сервис, который измеряет качество, скорость, стоимость и надёжность каждой модели на воспроизводимых задачах и трассирует всё в Langfuse. Это снимает главный риск интеграции LLM — «какую модель брать под задачу и бюджет» — превращая его из догадок в измеримое решение.

Что получает партнёр: - один контракт и один API вместо десятка интеграций с разными вендорами; - независимые, воспроизводимые данные о качестве/латентности/стоимости моделей; - готовый слой наблюдаемости и контроля затрат; - быстрый онбординг (drop-in замена OpenAI-клиента).

2. О платформе DataEyes

DataEyes (бренд 数眼 / **DataEyes**) — унифицированный интерфейс к множеству LLM. Ключевые свойства (подтверждены технической интеграцией):

- **Единый OpenAI-совместимый API** — `chat/completions`, Responses API, streaming, function calling. Дополнительно поддерживаются **Anthropic-совместимый** и **Gemini-совместимый** форматы — миграция с существующего стека минимальна.
- **Динамический каталог моделей** — `GET /v1/models`: список доступных моделей определяется вашим ключом, без хардкода.
- **Web Search / Reader API** — отдельный сервис живого веб-поиска (`api.dataeyes.ai`) для агентных сценариев.
- **Мульти-регион** — несколько точек входа для отказоустойчивости и близости к рынку:

Регион	Точка входа
Global	<code>https://cloud.dataeyes.ai/v1</code>
Китай (КНР)	<code>https://cloud-cn.shuyanai.com/v1</code>
Гонконг	<code>https://cloud-hk.dataeyes.ai/v1</code>
Web Search API	<code>https://api.dataeyes.ai</code>

- **Аутентификация** — `Authorization: Bearer <key>`.
- **Документация** — `dataeyes.ai`, `doc.dataeyes.ai`.

Юридические реквизиты вендора, официальные SLA и сертификации (data residency, ISO/SOC2 и т.п.) уточняются у DataEyes — см. раздел 12.

3. Проблема, которую мы закрываем

«Много моделей через один ключ» — это удобство, но в продакшене партнёр сталкивается с типовыми проблемами интеграции. Ниже — реальные классы инцидентов, которые наш бенчмарк выявляет **до** вывода в прод:

#	Проблема интеграции	Последствие	Как закрываем
1	Несовместимость endpoint (например, отсутствие <code>/v1</code> в base URL)	Клиент падает на старте	Валидация конфигурации, корректные дефолты
2	Часть «рекламируемых» моделей недоступна конкретному ключу	Сюрприз в проде	Динамический discovery <code>/v1/models</code>
3	Разное качество tool-calling / function calling между моделями	Невалидные аргументы инструментов	Скоринг tool-accuracy + JSON-fallback
4	Большой разброс latency (особенно first-token) между моделями	Непредсказуемый UX	Замер p50/p95 латентности
5	Поле стоимости отсутствует в ответе API	Невозможно атрибутировать затраты	Локальный расчёт по референс-ценам, <code>cost_status</code> без фабрики
6	Трассировка теряется, если запрос обошёл шлюз	Нет наблюдаемости	Принудительная маршрутизация + Langfuse
7	Rate-limit (429) при конкурентных вызовах	Сбои нагрузки	Контролируемый параллелизм, лимиты на прогон
8	«Грязный» JSON (markdown-обёртки, <code><think></code> -блоки)	Срыв strict-схем	Санитайзинг и извлечение JSON

Вывод: ценность не только в широте каталога, но и в **объективной приёмке моделей** перед интеграцией.

4. Что мы предлагаем

- 1. **Доступ к платформе DataEyes** — единый API к каталогу frontier-моделей (раздел 5), мульти-регион, drop-in совместимость.
- 2. **Независимый бенчмарк-сервис** (`model-bench`, открытый код) — воспроизводимая оценка моделей по 10 наборам тестов (suites): от smoke-проверок и строгих JSON-схем до многошаговых reasoning-, code- и system-design-задач и 5–10-шагового агентного сценария.
- 3. **Слой наблюдаемости и экономики** — трассировка каждого вызова в Langfuse (латентность, токены, токены/сек, оценочная стоимость, оценки качества), хранение артефактов и сводных отчётов.
- 4. **Отчётность под партнёра** — выгрузка результатов прогонов в человекочитаемые отчёты (Markdown/PDF) для принятия решений и презентаций конечным клиентам.

5. Каталог моделей и ориентировочная экономика

Доступ — к десяткам моделей ~10 вендоров через один API. Ниже — репрезентативная выборка с **ориентировочными ценами** (USD за 1 млн токенов, вход / выход), используемыми нашим бенчмарком для расчёта стоимости (актуальность — июнь 2026; официальный прайс DataEyes уточняется отдельно — см. раздел 12).

Премиум-класс (максимальное качество):

Модель	Вендор	Вход \$/1M	Выход \$/1M
claude-fable-5	Anthropic	10.00	50.00
gpt-5.5	OpenAI	5.00	30.00
claude-opus-4-8	Anthropic	5.00	25.00
gemini-3-pro-preview	Google	2.00	12.00
qwen3.7-max	Alibaba	2.50	7.50
kimi-k2-thinking	Moonshot	0.60	2.50
MiniMax-M2.7	MiniMax	0.28	1.20

Средний класс (баланс цена/качество):

Модель	Вендор	Вход \$/1M	Выход \$/1M
glm-5-turbo	Zhipu AI	1.20	4.00
deepseek-v4-pro	DeepSeek	0.435	0.87
gemini-3.5-flash	Google	0.15	0.60
gpt-4.1-mini	OpenAI	0.40	1.60

Экономичный класс (объём и скорость):

Модель	Вендор	Вход \$/1M	Выход \$/1M
gpt-5.4-nano	OpenAI	0.10	0.40
gemini-3.1-flash-lite	Google	0.10	0.40
deepseek-v4-flash	DeepSeek	0.14	0.28
doubao-seed-2-0-mini	ByteDance	0.05	0.20

Полный каталог (всего 36 моделей в референс-таблице) определяется динамически вашим ключом через `/v1/models`. Разброс цен между топовой и экономической моделью — **до ~100x по выходным токенам**, поэтому правильный выбор модели под задачу даёт основную экономию.

6. Доказательство: результаты независимого бенчмарка

Ниже — **реальный прогон** нашего инструмента: набор `deep_eval` (4 задачи × 100 баллов = 400), по одной флагманской модели на вендора, 10 моделей, **10 июня 2026**. Задачи: многошаговый reasoning, генерация кода, строгое следование инструкции, QA по длинному контексту.

#	Модель	Вендор	Балл / 400	Ср. латентность/задача
1	gpt-5.5	OpenAI	400	~9.2 с
1	gemini-3.5-flash	Google	400	~9.5 с
1	MiniMax-M2.7	MiniMax	400	~5.7 с (самый быстрый)
1	glm-5-turbo	Zhipu AI	400	~23.6 с
1	doubao-seed-2-0-pro	ByteDance	400	~48.4 с
1	qwen3.7-max	Alibaba	400	~56.9 с
7	claude-fable-5	Anthropic	390	~11.3 с
7	kimi-k2-thinking	Moonshot	390	~58.0 с
9	mimo-v2.5-pro	MiMo (Xiaomi)	370	~12.9 с
10	deepseek-v4-flash	DeepSeek	340	~22.7 с

Ключевые выводы (воспроизводимы): - **Качество подтянулось у всех топ-вендоров:** 6 из 10 моделей — идеальные 400/400 на этом наборе. - **Лучший баланс «скорость × качество»:** `gpt-5.5`, `gemini-3.5-flash`, `MiniMax-M2.7` — высший балл при низкой латентности (квадрант «быстро и точно»). `gemini-3.5-flash` — лидер по пропускной способности (~200+ выходных токенов/сек). - **Скрытые риски latency:** `kimi-k2-thinking` и `qwen3.7-max` дают высокий балл, но на задаче генерации кода доходят до **1.5–2.5 минут** на ответ — непригодны для интерактивных сценариев без оговорок. - **Самая сложная задача — QA по длинному контексту:** именно на ней «проседают» более слабые модели (`deepseek-v4-flash`, `mimo-v2.5-pro`).

Это точечный замер на фиксированном наборе задач, а не непрерывный SLA-мониторинг. Бенчмарк воспроизводим: любой партнёр может перепрогнать его на своём ключе и своих задачах и получить сопоставимые артефакты.

7. Технологические преимущества

- **Drop-in совместимость.** OpenAI / Anthropic / Gemini-форматы + Responses API + streaming + function calling — миграция существующего кода минимальна.
- **Мульти-регион и отказоустойчивость.** Global / CN / HK точки входа; прямой fallback на DataEyes при недоступности шлюза.
- **Надёжность прогона.** Изоляция ошибок по моделям (падение одной модели не валит весь прогон — статус `partial`), жёсткий wall-clock timeout на вызов, санитайзинг «грязного» JSON, поддержка thinking-моделей (извлечение reasoning-контента).
- **Наблюдаемость.** Двухуровневая трассировка в Langfuse: токен-уровень (через шлюз LiteLLM) + прикладной уровень (run/case-спаны и оценки). Метаданные: run_id, suite, case_id, модель, вендор.
- **Экономика без фабрикаций.** Стоимость считается по прозрачной референс-таблице; если данных нет — честный статус `unknown`, а не выдуманное число.
- **Хранилище и экспорт.** PostgreSQL (прогоны, результаты, события, артефакты) + S3-совместимое хранилище (сырые ответы, отчёты, выгрузки) с локальным fallback.
- **Инженерная зрелость.** Открытый код, тесты (27 проходят), линт (ruff), CI/CD (тесты на Python 3.11/3.12, CodeQL, gitleaks, Dependabot) — прозрачно и проверяемо.

8. Модели сотрудничества для партнёров

Варианты (обсуждаемы и комбинируемы):

1. **Реселл / посредничество доступа** к DataEyes под ключ партнёра.
2. **Интеграция «под ключ»** — внедрение единого API + слоя наблюдаемости/экономики в продукт партнёра.
3. **Benchmark-as-a-service** — регулярные независимые прогоны под задачи партнёра с отчётами под его бренд (white-label).
4. **Совместный go-to-market** — пакетирование «доступ к моделям + объективный выбор модели» для конечных клиентов партнёра.

Конкретная модель, разделение зон ответственности и условия — предмет переговоров (раздел 10).

9. Как начать (внедрение)

1. **Доступ.** Партнёр получает ключ DataEyes; проверяем доступный каталог через `/v1/models`.
2. **Smoke-проверка.** Запускаем `smoke`-набор — подтверждаем связность, JSON-валидность, базовую латентность.

- 3. **Профильные наборы.** Подбираем suites под задачи партнёра (`json_schema` , `agent_mini` , `deep_eval` , `fast` и т.д.).
 - 4. **Наблюдаемость.** Подключаем Langfuse — все вызовы, метрики и оценки видны в реальном времени.
 - 5. **Решение.** По сводному отчёту (качество × латентность × стоимость) фиксируем модели под каждый сценарий.
- Технически сервис поднимается за день: `make up && make migrate && make dev` (PostgreSQL + хранилище + шлюз), затем `curl /benchmarks/run` . Ориентировочный срок пилота — **[1–2 недели – согласовать]** .

10. Коммерческие условия

Параметр	Значение
Модель оплаты доступа к моделям	По факту потребления токенов; тарифы DataEyes — по запросу
Стоимость внедрения / интеграции	Рассчитывается под объём работ, обсуждается индивидуально
Benchmark-as-a-service	По запросу: разовый прогон или регулярный мониторинг
Партнёрское вознаграждение / реселл	Обсуждается индивидуально
SLA, лимиты (RPM/TPM), поддержка	По договорённости (официальные SLA DataEyes уточняются у вендора)
Срок действия предложения	30 дней с даты подготовки (до 13 июля 2026)

Точные цифры формируются под профиль и объём партнёра — готов рассчитать после короткого созвона.

11. Контакты

- **Представитель:** Данил Силантьев
- **Email:** danilsilantyevwork@gmail.com
- **Проект / демо** (открытый бенчмарк): github.com/rldyourmnd/dataeyes
- **Telegram / телефон:** по запросу

12. Приложения и оговорки

- **Источник цен.** Цены в разделе 5 — ориентировочные вендорские цены (USD/1M токенов, июнь 2026), заложенные в бенчмарк для расчёта стоимости. Это **не** официальный прайс-лист DataEyes; DataEyes в ответах API стоимость не передаёт, поэтому она оценивается локально или помечается как недоступная. Официальные тарифы DataEyes уточняются у вендора.

- **Источник результатов бенчмарка.** Раздел 6 — реальный прогон `deep_eval` от 2026-06-10 (10 моделей, по одной на вендора). Это точечный замер на фиксированном наборе задач, воспроизводимый на стороне партнёра; он не является непрерывным мониторингом или гарантией SLA.
 - **Не подтверждены в материалах и требуют уточнения у DataEyes:** юридические реквизиты вендора, официальные SLA/uptime, сертификации и data residency (GDPR/SOC2/ISO 27001), лимиты тарифов, размеры контекстных окон.
 - **Инструмент.** Бенчмарк-сервис (`model-bench`) — открытый код в монорепо `dataeyes`; методология, наборы тестов и скоринг прозрачны и проверяемы.
-

Документ подготовил Данил Силантьев на основе верифицируемых данных репозитория `dataeyes`. Тарифы DataEyes, официальные SLA и сертификации уточняются у вендора; коммерческие детали — индивидуально по запросу.